

پروپوزال پروژه

موضوع

طراحی و ارزیابی رویکردی برای بهبود زمان‌بندی وظایف یادگیری ماشین در Kubernetes

امیر میرزائی موحد

مجید بافنده

شماره دانشجویی: ۴۰۴۱۲۵۰۵۹

شماره دانشجویی: ۴۰۴۱۳۱۰۴۳

متن پروپوزال

بیان مسئله. با گسترش استفاده از هوش مصنوعی، اجرای بارهای کاری مربوط به آموزش، پردازش داده و استنتاج مدل‌ها در محیط‌های ابری اهمیت زیادی پیدا کرده است. در این میان، Kubernetes یکی از رایج‌ترین بسترها برای اجرای برنامه‌های کانتینری و مدیریت منابع در محیط‌های ابری است. با این حال، زمان‌بند پیش‌فرض آن عمدتاً برای بارهای کاری عمومی طراحی شده و الزاماً ویژگی‌های خاص وظایف هوش مصنوعی را در تصمیم‌گیری لحاظ نمی‌کند. این وظایف ممکن است از نظر شدت محاسباتی، مدت اجرا، مصرف منابع، نیازهای ورودی و خروجی و رفتار اجرایی تفاوت زیادی با یکدیگر داشته باشند. نادیده گرفتن این تفاوت‌ها می‌تواند باعث استفاده غیربهره‌مند از منابع، افزایش زمان تکمیل وظایف و کاهش کارایی کلی سیستم شود.

پرسش پژوهشی. چگونه می‌توان با طراحی و پیاده‌سازی یک سیاست زمان‌بندی آگاه از ویژگی‌های بارهای کاری یادگیری ماشین در Kubernetes، کارایی اجرای وظایف را نسبت به زمان‌بندی عمومی و پیش‌فرض بهبود داد؟ برای پاسخ به این پرسش، ابتدا محدودیت‌های زمان‌بندی عمومی در مواجهه با بارهای کاری ناهمگون یادگیری ماشین بررسی می‌شود. سپس مجموعه‌ای از ویژگی‌های قابل استفاده برای توصیف رفتار وظایف تعریف می‌گردد؛ مانند شدت محاسباتی، مدت تقریبی اجرا، میزان مصرف منابع، الگوی ورودی و خروجی یا سایر مشخصات مرتبط با اجرای وظیفه. در ادامه، یک سیاست زمان‌بندی قابل تنظیم طراحی می‌شود که بتواند بر اساس این ویژگی‌ها تصمیم‌های آگاهانه‌تری درباره ترتیب یا نحوه اجرای وظایف اتخاذ کند.

راهکار پیشنهادی و ارزیابی. راهکار پیشنهادی به صورت یک نمونه اولیه در محیط Kubernetes پیاده‌سازی خواهد شد. بسته به روند پیاده‌سازی، این راهکار می‌تواند به شکل یک زمان‌بند سفارشی، یک لایه کنترلی مکمل یا یک سازوکار مدیریت اجرای Job‌ها در Kubernetes پیاده‌سازی شود. در مرحله ارزیابی می‌توان از مجموعه‌ای از وظایف آزمایشی، شبیه‌سازی شده یا داده‌های حاصل از اجرای نمونه برای بررسی رفتار روش پیشنهادی استفاده کرد. همچنین در صورت امکان، عملکرد رویکرد پیشنهادی با زمان‌بند پیش‌فرض Kubernetes یا یک روش پایه مقایسه خواهد شد. معیارهای ارزیابی می‌توانند شامل میانگین زمان تکمیل وظایف، زمان کل اتمام همه وظایف و میزان استفاده مؤثر از منابع باشند.

انتظار و خروجی پروژه. انتظار می‌رود این پروژه نشان دهد که استفاده از اطلاعات مربوط به ماهیت و رفتار بارهای کاری می‌تواند به تصمیم‌گیری بهتر در زمان‌بندی وظایف هوش مصنوعی کمک کند. تمرکز اصلی پروژه بر طراحی یک رویکرد انعطاف‌پذیر و قابل توسعه است؛ به گونه‌ای که بتوان آن را برای انواع مختلف بارهای کاری و شرایط اجرایی متفاوت تنظیم و ارزیابی کرد.

منابع

- [۱] Z. Rejiba and J. Chamanara, "Custom Scheduling in Kubernetes: A Survey on Common Problems and Solution Approaches," *ACM Computing Surveys*, vol. ۵۵, no. ۷-۱۵۱:۱, ۱۵۱:۳۷ Dec. ۱۵, ۲۰۲۲ ISSN: ۰۳۰۰-۰۳۶۰ DOI: 10.1145/3544788 Accessed: Jul. ۳, ۲۰۲۶ [Online]. Available: <https://dl.acm.org/doi/10.1145/3544788>