

گزارش پایانی پروژه

موضوع

طراحی و ارزیابی رویکردی برای بهبود زمان‌بندی وظایف یادگیری ماشین در Kubernetes

سامانه پیاده‌سازی شده: KubeML-Aware

امیر میرزائی موحد

شماره دانشجویی: ۴۰۴۱۲۵۰۵۹

مجید بافنده

شماره دانشجویی: ۴۰۴۱۳۱۰۴۳

۱. خلاصه پروژه

در این پروژه یک لایه پذیرش آگاه از رتبه برای بارهای کاری آموزش یادگیری ماشین در Kubernetes با نام KubeML-Aware طراحی و پیاده‌سازی شد. برخلاف رویکردهایی که زمان‌بند پیش‌فرض را جایگزین می‌کنند، این سامانه تنها زمان واجد شرایط شدن پادها^۱ برای زمان‌بندی را کنترل می‌کند و وظایف فیلترکردن گره‌ها، امتیازدهی و اتصال^۲ را همچنان به زمان‌بند پیش‌فرض واگذار می‌کند. سازوکار کار به این صورت است که همه پادهای یک دسته^۳ پشت یک دروازه زمان‌بندی پایدار نگه داشته می‌شوند؛ پس از کامل شدن دسته، یک کنترلر شش ویژگی هر وظیفه را اعتبارسنجی می‌کند، یک رتبه قطعی^۴ محاسبه می‌کند و دروازه‌ها را به ترتیب رتبه و بر اساس بازخورد منابع برمی‌دارد. این طراحی امکان بهبود ترتیب اجرای وظایف را بدون از دست دادن ایمنی و پایداری زمان‌بند اصلی فراهم می‌کند.

۲. دستاوردهای اصلی

مهم‌ترین خروجی‌های عملی پروژه عبارت‌اند از: الگوریتم رتبه‌بندی شش ویژگی با نرمال‌سازی درون‌دسته‌ای و مدیریت رتبه‌های یکسان؛ سازوکار FastPath که با استفاده از تله‌متری^۵ تازه منابع، فاصله‌های خالی صف زمان‌بند را حذف می‌کند و در صورت کهنه‌بودن داده‌ها به صورت ایمن (fail-closed) عمل می‌کند؛ یک tail-balancer برای بازچینش وظایف کم‌اهمیت‌تر؛ بسته استقرار Helm به همراه تنظیمات RBAC؛ و در نهایت اجرای دو دور آزمایش واقعی روی خوشه K3s. در ارزیابی آزمایشی اولیه (دوازده وظیفه، پنج تکرار جفتی)، میانگین زمان تکمیل وظیفه^۶ بهبود ۷/۳۸ درصدی داشت. در ارزیابی نهایی و در مقیاس بزرگ یک دسته ۲۰۰ وظیفه‌ای، میانگین JCT حدود ۳۰ درصد، صدک ۹۵ زمان تکمیل (p95 JCT) حدود ۱۳/۷ درصد و زمان کل اتمام دسته (makespan) حدود ۱۲/۸ درصد نسبت به زمان‌بند پیش‌فرض Kubernetes بهبود یافتند.

۳. فعالیت‌های انجام شده

با توجه به دو نفره بودن پروژه، حجم کار به گونه‌ای انتخاب شد که فراتر از یک پروژه تک‌نفره باشد؛ علاوه بر طراحی الگوریتم و نگارش مقاله، یک سامانه کامل و آماده استقرار در Kubernetes همراه با مجموعه گسترده‌ای از آزمون‌ها پیاده‌سازی و بر روی یک سرور ارزیابی شد. فعالیت‌های پروژه را می‌توان در چهار حوزه اصلی زیر دسته‌بندی کرد:

الف) پیاده‌سازی و توسعه سامانه. در این بخش، هسته کنترلر دروازه‌ای (gate controller)، الگوریتم رتبه‌بندی (rank)، منطق اجرا و ثبت رویدادها (records, execution)، سازوکار جمع‌آوری دسته (burst)، مسیر سریع (fast_path)، تنظیم آهنگ تطبیقی (pacing) و مدل کار مصنوعی آموزش (work_model) توسعه یافتند. همچنین بسته Helm، منابع RBAC و مانیفست‌های Knative برای استقرار امن آماده شدند.

^۱ Pod: واحد اجرایی در Kubernetes

^۲ Pod

^۳ batch

^۴ deterministic

^۵ telemetry

^۶ JCT

(ب) **آزمایش و جمع‌آوری داده.** مجموعه‌ای از بارهای کاری متنوع (کوچک، متوسط، بزرگ، ناهمگون و ابلیشن^۷) طراحی شد و پروتکل آزمایش جفتی^۸ توسط K3s با پنج تکرار و دوازده وظیفه در هر بازو^۹ اجرا گردید. کد جمع‌آوری متریک‌ها (metrics_collector)، تله‌متری و ثبت رویدادهای سطح برنامه برای اندازه‌گیری دقیق JCT و makespan توسعه داده شد. در گام بعد، برای افزایش توان آماری و بررسی رفتار سامانه در مقیاس واقعی‌تر، یک دور دوم آزمایش با ۲۰۰ وظیفه یادگیری ماشین ناهمگون که با شش ویژگی رتبه‌بندی (مدت زمان تخمینی، نرخ کاهش خطا، بُعد ماتریس، حجم به‌روزرسانی گرادیان، فاصله نقطه بازرسی و تعداد افراز مدل) توصیف می‌شدند به‌صورت یک دسته واحد روی K3s اجرا و در چهار پیکربندی مقایسه شد: زمان‌بند پیش‌فرض Kubernetes، رتبه‌بندی تک‌ویژگی بر مبنای مدت زمان (duration-only)، الگوریتم کامل شش‌ویژگی KubeML-Aware، و یک کنترل ابلیشن با رتبه‌بندی معکوس شده (برای بررسی جهت اثر).

(ج) **تحلیل نتایج و نگارش مقاله.** داده‌های خام آزمایش با اسکریپت‌های تحلیل آماری پردازش شد. سپس مقاله نهایی به سبک IEEE به همراه شکل‌های معماری، بافت Kubernetes، نمودار نتایج و خط‌زمانی اجرا تدوین و در چند مرحله بازبینی شد.

(د) **آزمون و رفع اشکال.** یک مجموعه جامع از آزمون‌های واحد و یکپارچگی برای همه بخش‌ها (رتبه‌بندی، کنترلرها، اجرا، مسیر سریع، تله‌متری، تولید بار کاری و اعتبارسنجی مانیفست‌ها) نوشته شد. در این مرحله باگ‌های مربوط به تجزیه لاگ‌ها شناسایی و برطرف شد و صحت مانیفست‌های Kubernetes پیش از استقرار اعتبارسنجی گردید.

۴. نقش و سهم هر یک از اعضا

مطابق خواسته درس، نقش هر عضو در ادامه به‌صورت دقیق و صریح مشخص شده است. نکته اصلی این است که هر دو عضو در تمام بخش‌های پروژه شامل نگارش مقاله، کدنویسی، اجرای آزمایش‌ها و رفع اشکال به‌صورت فعال مشارکت داشته‌اند و هیچ بخشی به‌طور کامل بر عهده تنها یک نفر نبوده است. تصمیم‌های اصلی طراحی، ساختار مقاله و تحلیل نتایج به‌صورت مشترک اتخاذ شده است. با این حال، برای شفافیت بیشتر، مسئولیت اصلی/راهنبری هر حوزه به شکل زیر تقسیم شده است: اعضای گروه به‌صورت مشترک در تمامی مراحل پروژه مشارکت داشتند. هر دو عضو در طراحی و پیاده‌سازی هسته کنترلر دروازه‌ای، الگوریتم رتبه‌بندی شش‌ویژگی، سازوکار FastPath، طراحی بارهای کاری، اجرای آزمایش‌ها روی K3s، جمع‌آوری و تحلیل داده‌ها، توسعه و اجرای آزمون‌ها، رفع اشکال و نگارش و بازبینی مقاله نقش فعال داشتند. تصمیم‌های فنی، طراحی‌های اصلی و تحلیل نتایج نیز به‌صورت مشترک انجام شد و هیچ‌یک از بخش‌های پروژه به‌طور مستقل به یکی از اعضا اختصاص نداشت.

۵. نتایج کلیدی

۱.۵ ارزیابی پایلوت (دوازده وظیفه، پنج تکرار)

دور نخست ارزیابی روی یک گره چهارهسته‌ای اشتراکی K3s و با پنج تکرار جفتی انجام شد. نتایج در جدول زیر خلاصه شده‌اند. میانگین زمان تکمیل وظیفه در تمام پنج جفت بهبود یافت و بهبود میانگین جفتی برابر ۷/۳۸ درصد (با بازه اطمینان اکتشافی ۹۵ درصد برابر [۲/۵۷، ۱۲/۰۵]) به‌دست آمد. زمان کل اتمام دسته (makespan) نیز در هر پنج جفت در همان جهت کاهش یافت (۲/۴۷ درصد)، اما چون بازه اطمینان آن شامل صفر است، در آن مرحله به‌عنوان یک روند جهت‌دار و نه یک اثر قطعی گزارش شد.

معیار	FIFO پایه	KubeML-Aware	بهبود
میانگین JCT	۳۱/۰۵ ثانیه	۲۸/۷۶ ثانیه	+۷/۳۸٪
Makespan	۵۵/۳۷ ثانیه	۵۴/۰۱ ثانیه	+۲/۴۷٪

ablation^۷
paired^۸
arm^۹

۲.۵ ارزیابی نهایی در مقیاس بزرگ (۲۰۰ مرحله)

از آنجا که نتایج پایلوت امیدوارکننده ولی از نظر آماری محدود بودند (به‌ویژه برای makespan)، دور دوم آزمایش با هدف افزایش توان آماری و سنجش پایداری اثر در مقیاس بزرگ طراحی شد. در این دور، یک دسته ۲۰۰ وظیفه یادگیری ماشین ناهمگون روی همان سرویس K3s اجرا و در چهار پیکربندی مقایسه گردید: زمان‌بند پیش‌فرض Kubernetes (خط پایه)، رتبه‌بندی تک‌ویژگی duration-only، الگوریتم کامل شش‌ویژگی KubeML-Aware، و یک کنترل ابلیشن با رتبه معکوس شده. نتایج نسبت به خط پایه در جدول زیر آمده است:

پیکربندی	میانگین JCT	p95 JCT	Makespan
Kubernetes پیش‌فرض (خط پایه)	۹۹۰/۸ ثانیه	۱۲۹۶/۶ ثانیه	۱۳۰۴/۵ ثانیه
رتبه‌بندی duration-only	۷۳۷/۹ ثانیه (+۲۵/۵٪)	۱۱۵۳/۲ ثانیه (+۱۱/۱٪)	۱۱۶۰/۸ ثانیه (+۱۱/۰٪)
KubeML-Aware (کامل)	۶۹۳/۶ ثانیه (+۳۰/۰٪)	۱۱۱۸/۶ ثانیه (+۱۳/۷٪)	۱۱۳۷/۶ ثانیه (+۱۲/۸٪)
ابلیشن رتبه معکوس	۱۲۳۵/۵ ثانیه (-۲۴/۷٪)	۱۴۴۳/۴ ثانیه (-۱۱/۳٪)	۱۴۴۷/۱ ثانیه (-۱۰/۹٪)

در این مقیاس، الگوریتم کامل KubeML-Aware در هر سه معیار بهترین عملکرد را داشت: میانگین JCT حدود ۳۰ درصد، p95 JCT حدود ۱۳/۷ درصد و makespan حدود ۱۲/۸ درصد نسبت به زمان‌بند پیش‌فرض بهبود یافتند. نکته قابل توجه این است که رتبه‌بندی شش‌ویژگی به‌طور پیوسته از رتبه‌بندی تک‌ویژگی duration-only بهتر عمل کرد، که نشان می‌دهد ویژگی‌های اضافی (نرخ کاهش خطا، بُعد ماتریس، حجم به‌روزرسانی گرادیان، فاصله نقطه بازرسی و تعداد افزاز مدل) اطلاعات مفیدی فراتر از مدت زمان تخمینی به الگوریتم می‌افزایند. کنترل ابلیشن با رتبه معکوس شده، در هر سه معیار عملکردی به‌طور محسوسی بدتر از خط پایه داشت (کاهش عملکرد بین ۱۱ تا ۲۵ درصد)؛ این الگو یک شاهد مهم است که بهبود مشاهده‌شده ناشی از جهت درست سیگنال رتبه‌بندی است و نه صرفاً اثر جانبی مکانیزم دروازه‌بندی یا سربار زمان‌بندی.

۶. تحلیل تکمیلی و اعتبارسنجی

برای اطمینان از قابلیت‌آلودن نتایج مقیاس بزرگ، سه بررسی تکمیلی انجام شد. نخست، توزیع تجمعی تجربی (ECDF) زمان تکمیل وظایف در هر چهار پیکربندی رسم و مقایسه شد؛ منحنی KubeML-Aware در بیشتر بازه صدک‌ها به‌طور پیوسته سمت چپ منحنی خط پایه قرار دارد که نشان‌دهنده بهبود یکنواخت و نه فقط جابه‌جایی میانگین است. دوم، منحنی تکمیل تجمعی وظایف بر حسب زمان از شروع دسته بررسی شد که نشان داد KubeML-Aware با وجود شروع کندتر در وظایف نخست (به دلیل انتظار برای تکمیل شدن دسته پشت دروازه زمان‌بندی)، به سرعت روند سریع‌تری در تکمیل وظایف باقی‌مانده پیدا می‌کند و در پایان دسته ۲۰۰ وظیفه‌ای زودتر از خط پایه به اتمام می‌رسد. سوم، سازگاری جهت اثر بین دو دور آزمایش (پایلوت و مقیاس بزرگ) و همچنین بین سه معیار مختلف (میانگین، صدک ۹۵ و makespan) بررسی شد؛ در هر دو دور و هر سه معیار، پیکربندی KubeML-Aware به‌طور پیوسته بهتر از خط پایه و بهتر از نسخه duration-only بود، که اطمینان بیشتری نسبت به پایداری اثر مشاهده‌شده فراهم می‌کند.

۷. جمع‌بندی

در مجموع، این پروژه نشان داد که می‌توان یک سیاست پذیرش آگاه از ویژگی‌های یادگیری ماشین را بدون جایگزینی موتور مکان‌یابی Kubernetes افزود و به بهبود قابل‌مشاهده و پایدار در میانگین زمان تکمیل وظایف، صدک ۹۵ و زمان کل اتمام دسته رسید. نتایج پایلوت (بهبود ۷/۳۸ درصدی در مقیاس کوچک) و نتایج مقیاس بزرگ (بهبود حدود ۳۰ درصدی در میانگین JCT) هم‌جهت هستند و اعتماد بیشتری به اثر واقعی الگوریتم رتبه‌بندی می‌دهند. گام بعدی، اجرای آزمایش روی خوشه اختصاصی (به‌جای گره اشتراکی) با تکرارهای بیشتر و بارهای کاری واقعی چارچوب‌های یادگیری ماشین (به‌جای مدل‌سازی شده) است تا این نتایج در شرایط تولید نیز تأیید شوند.